Análisis de distribución de infecciones virales en jovenes de un muestreo del Hospital Gutierrez, Argentina

Estadística avanzada

Sol Abalo & Nicolás Salvatore

2026

Objetivos

- Analizar un conjunto de datos sobre infecciones virales (positivo vs. negativos) en población de jovenes del hopital Gutierrez.

- Analizar la calidad de los datos para establecer cuales requieren correcciones y criterios de filtrado de los mismos.

- Estudiar el efecto de si existe una relación entre la cantidad de eventos de un virus y la localidad de donde proviene el joven.

Hipótesis estadísticas

- H0 : La distribución de casos positivos entre los distintos virus es independiente de la localidad; es decir, la proporción relativa de casos atribuible a cada virus no presenta diferencias estadísticamente significativas entre localidades.

- H1 : La distribución de casos positivos entre los distintos virus depende de la localidad; es decir, existe al menos una localidad cuya distribución relativa de casos entre virus difiere significativamente de la esperada.

Formalmente

H0 : P(Virus = j | Localidad = i) = P(Virus = j)

H1 : ∃ i,j: P(Virus = j | Localidad = i) ≠ P(Virus = j)

Flujo de trabajo

1- Tabla de datos crudos .csv

2- Carga y conversión a Data Frame (Python 3.3)

3- Limpieza y corrección de irregularidades de nombres de ciudades



4- Limpieza de valores NA

5- Limpieza y corrección de valores de las pruebas de virus (Solo admitir : +, -)

6- Eliminación y limpieza de edades sin sentido (>18 años)

7- Corrección de la categorías de sexo

8- Graficar la cantidad de + y - del virus por ciudad.

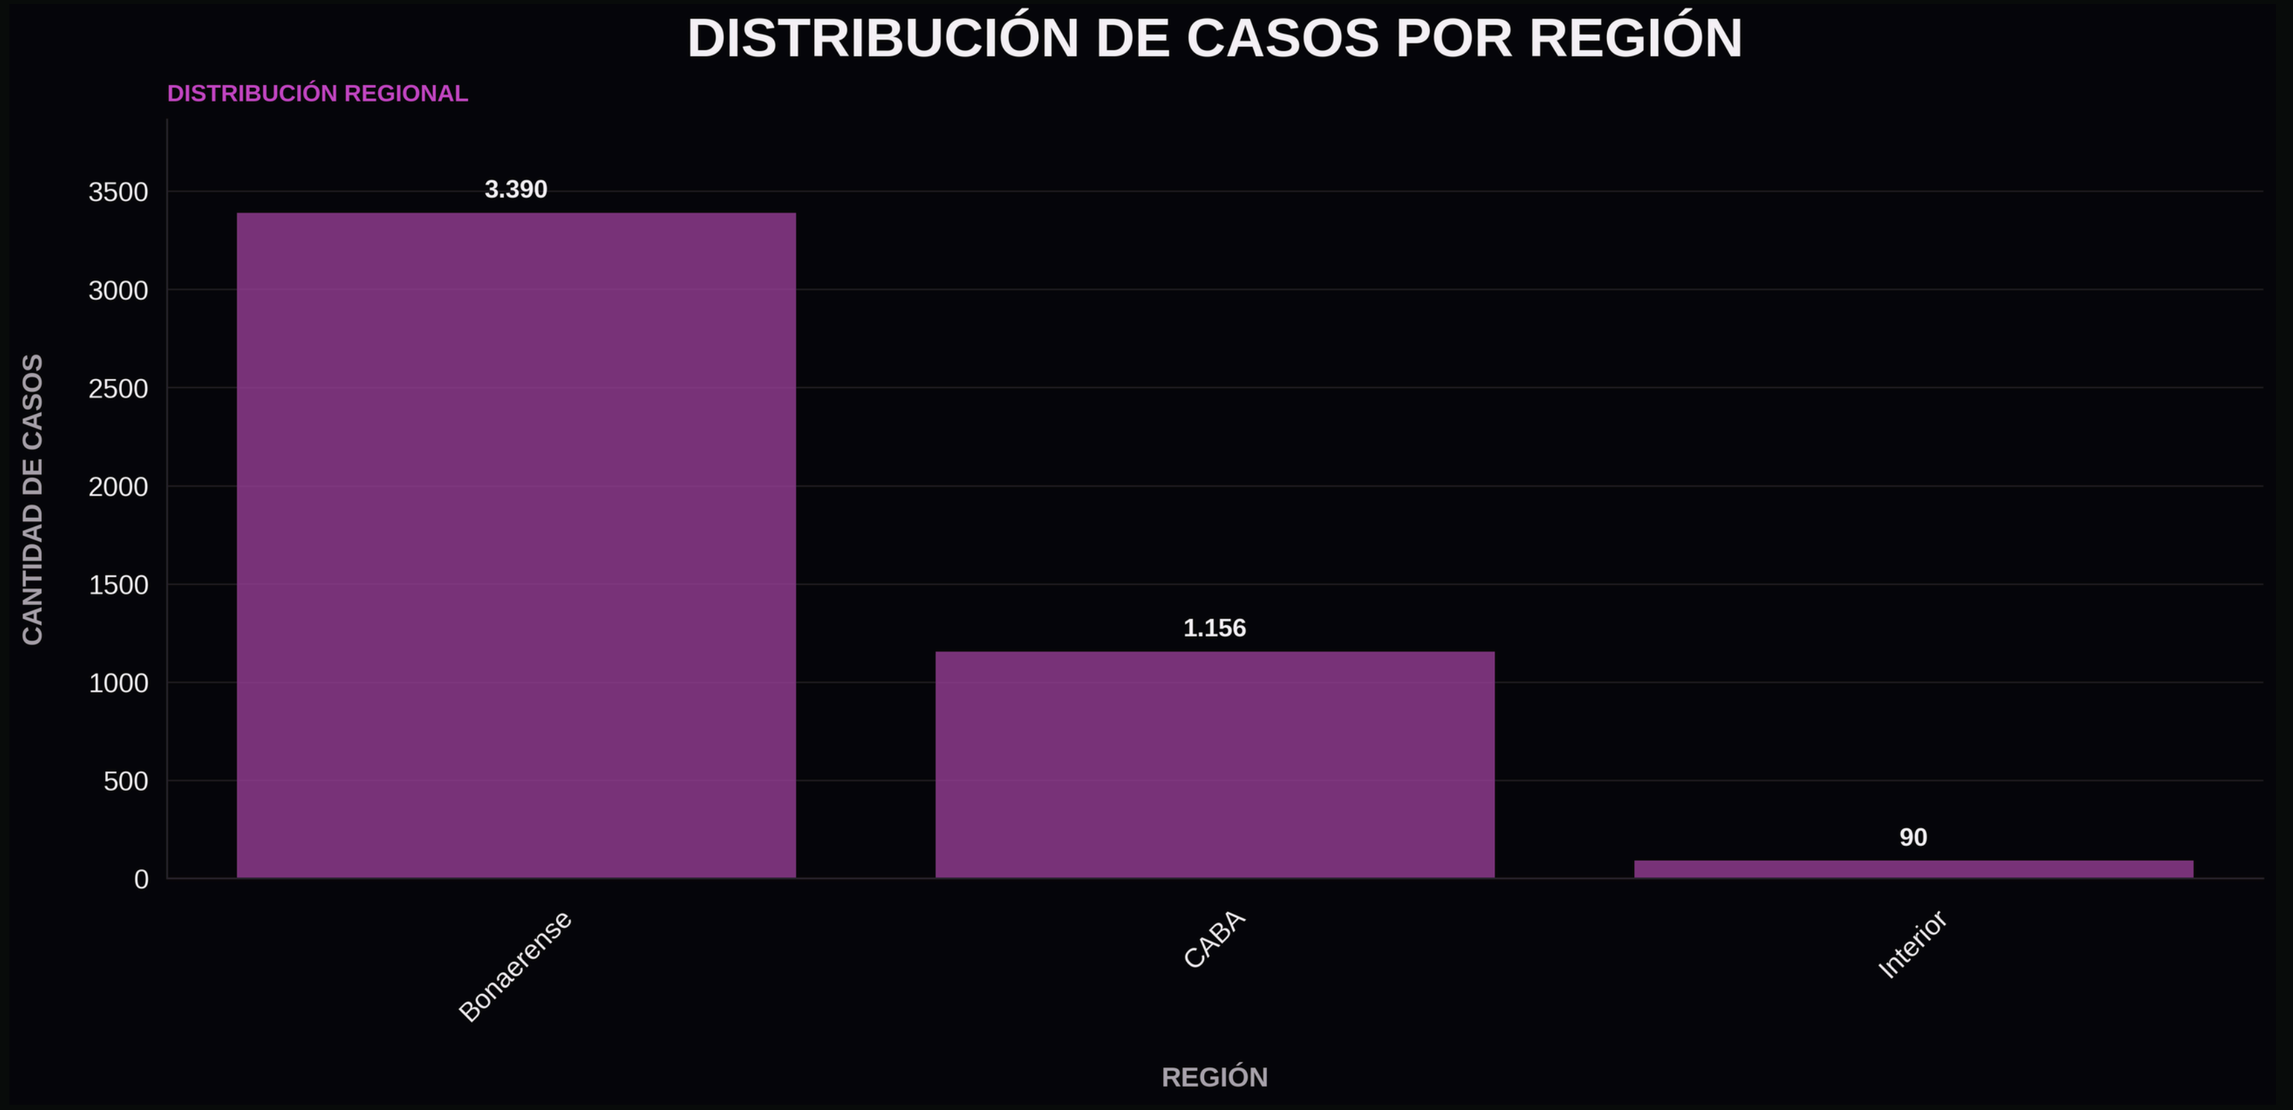
9- Análisis de la distribución

3- Limpieza y corrección de irregularidades



Observación : A simple vista, la asimetría de los casos tiene sentido por la distancia de cada ciudad al hospital donde se hicieron las pruebas.

3- Limpieza y corrección de irregularidades de nombres de ciudades

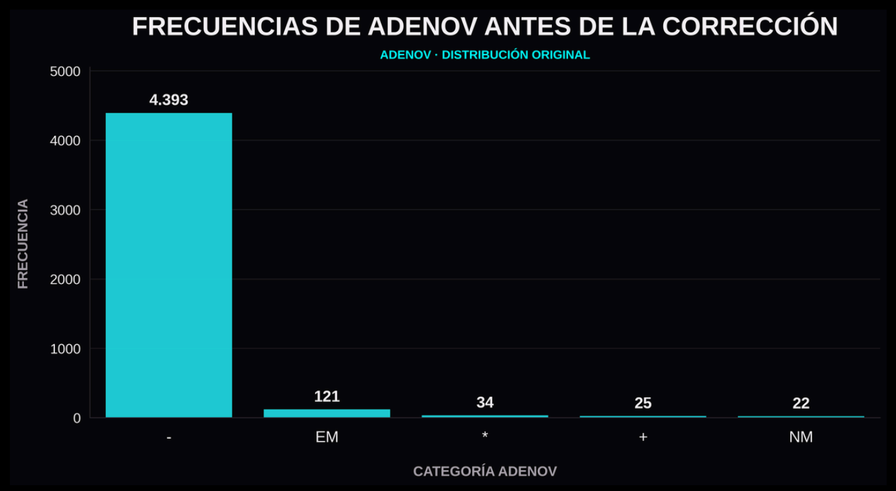


Observación 2 : Tiene sentido que no hayan tantos casos registrados de provincias o regiones que no sean de Buenos Aires.

Observación 3 : Esta asimetría en las frecuencias no invalida la hipótesis propuesta. Esto parece reflejar más bien cconsistente el gradiente espacial de utilización: las localidades más cercanas al hospital concentran una mayor proporción de visitas, mientras que la frecuencia de utilización tiende a disminuir a medida que aumenta la distancia al establecimiento.

5- Eliminar categorías sin sentido de las pruebas de los virus.

Ejemplo de la corrección en los valores de pruebas de Adenovirus



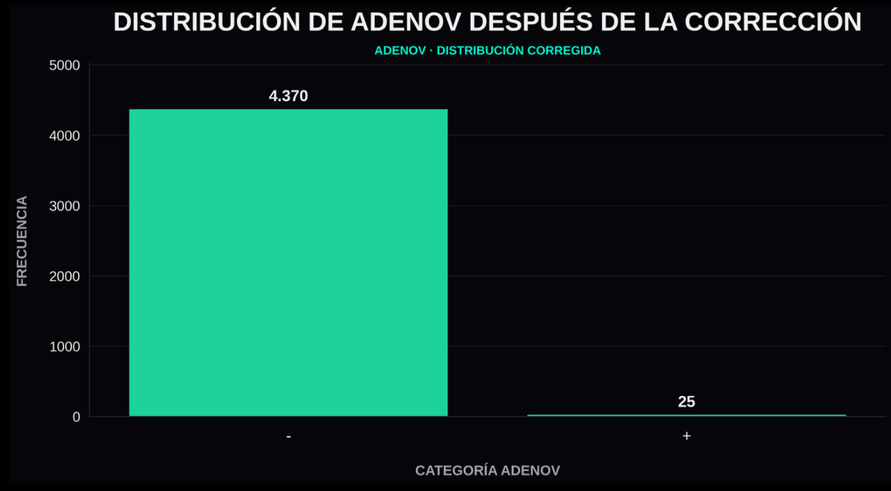
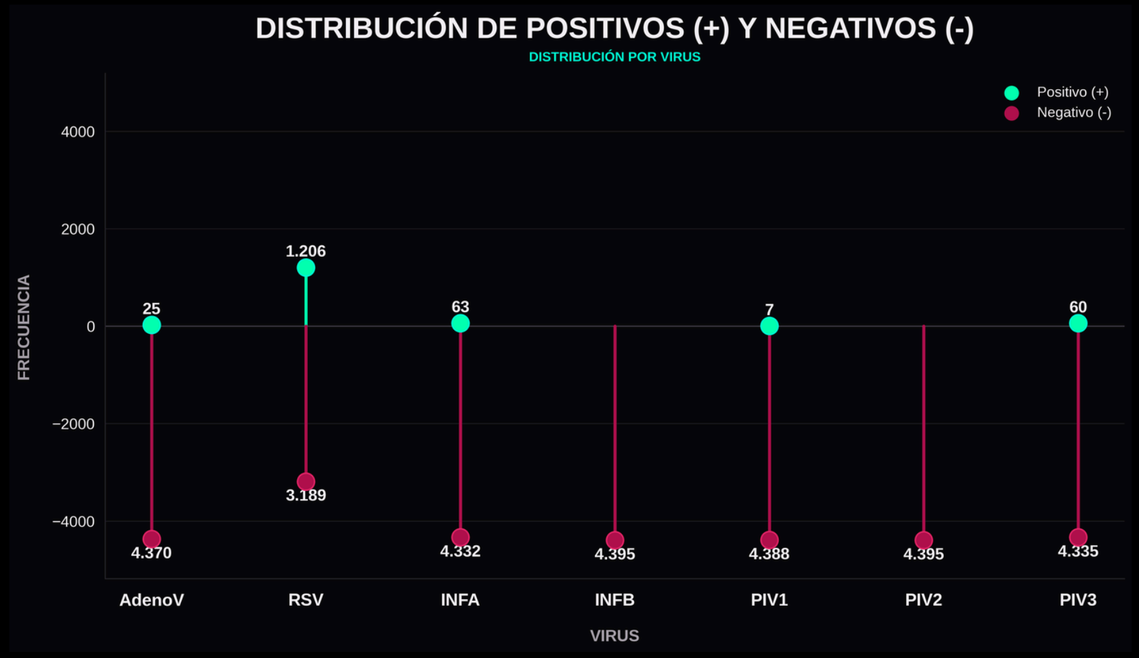


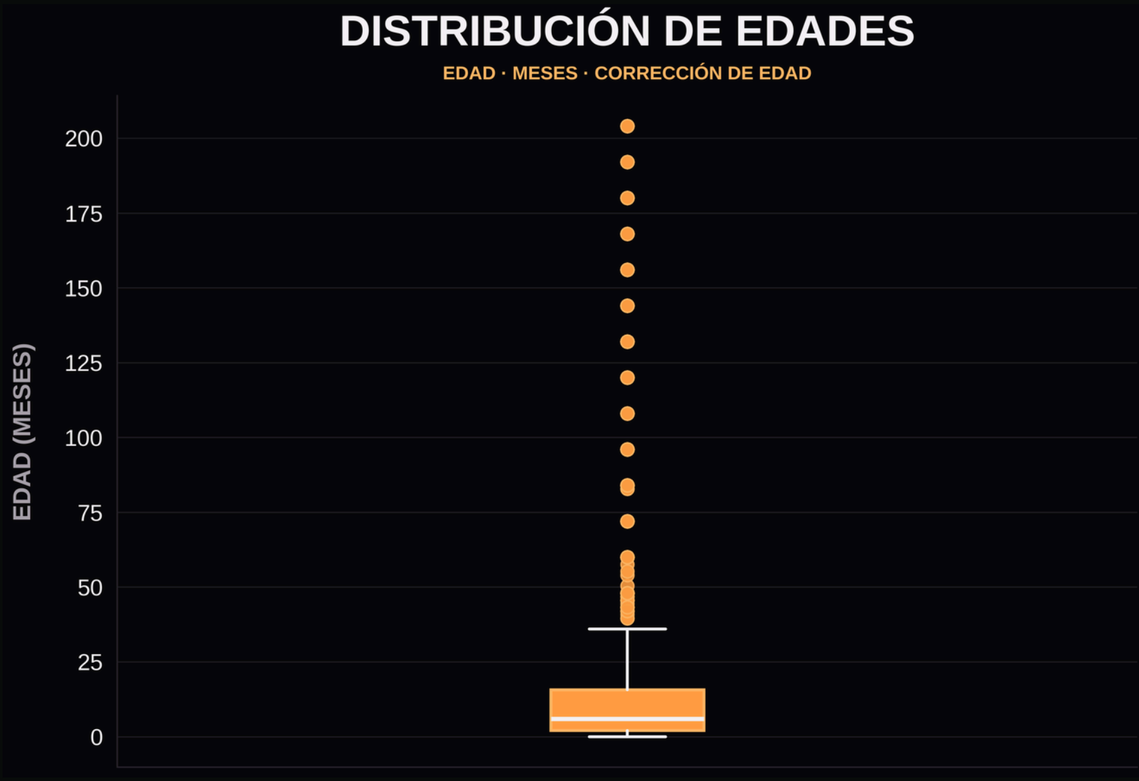
Gráfico lollipod exploratorio de casos + o – de cada prueba de virus



Observación 3: Con ese gráfico ya se sospecha que no todos los virus tuvieron la misma aparición en total. Parece haber cuasi uniformidad de valores – sin considerar a RSV.

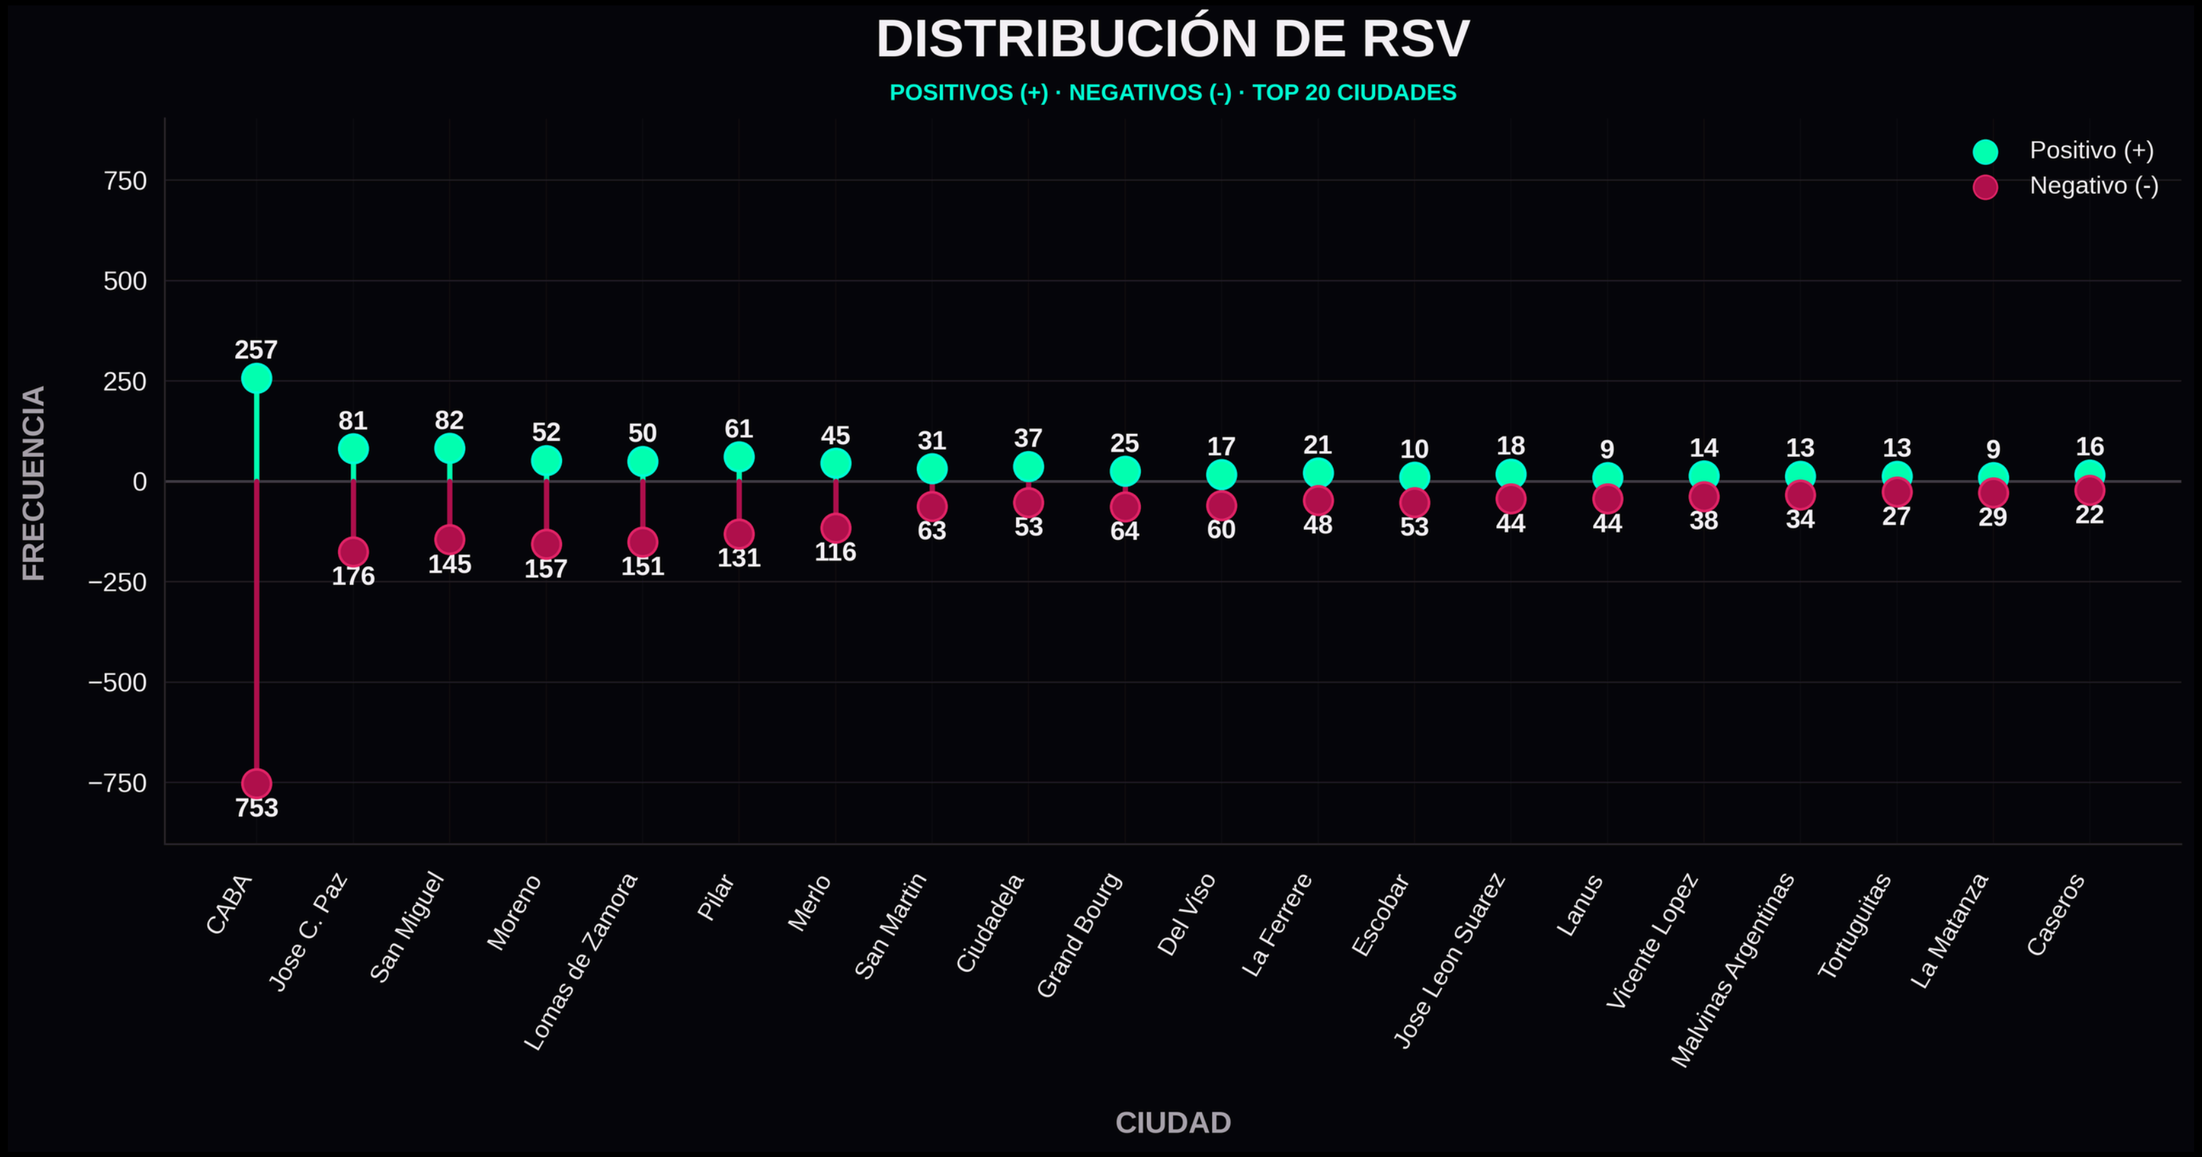
6- Corrección de edades ↣ Se usó el criterio de z-score





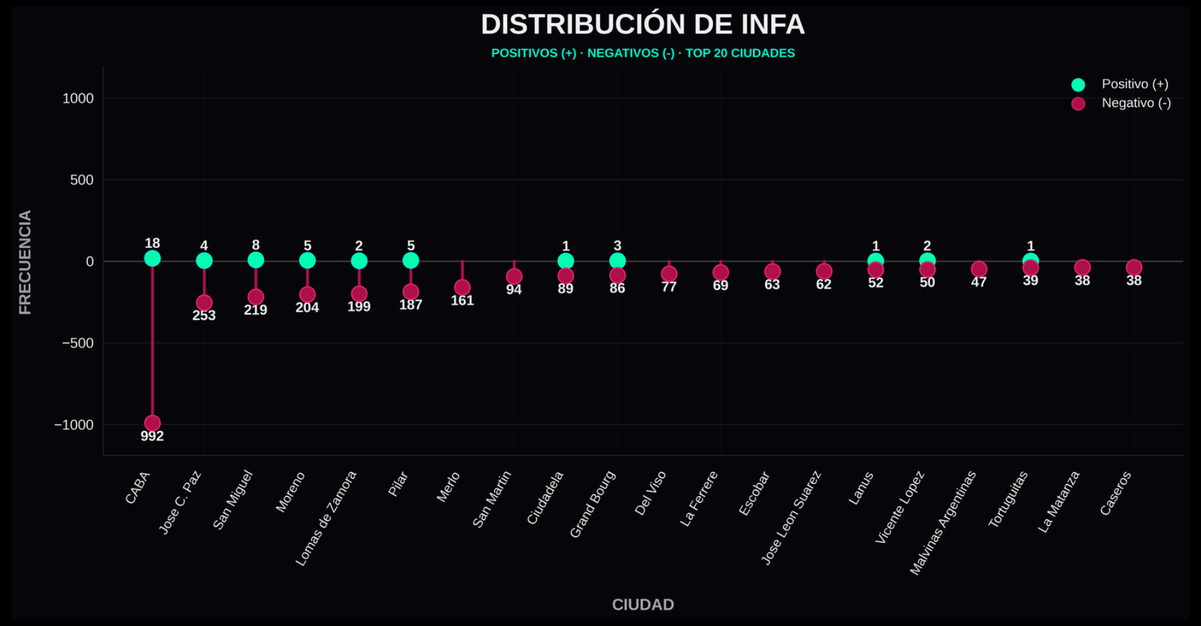
Observación 4 : Con este criterio, el máximo de edad fue de 204 meses.

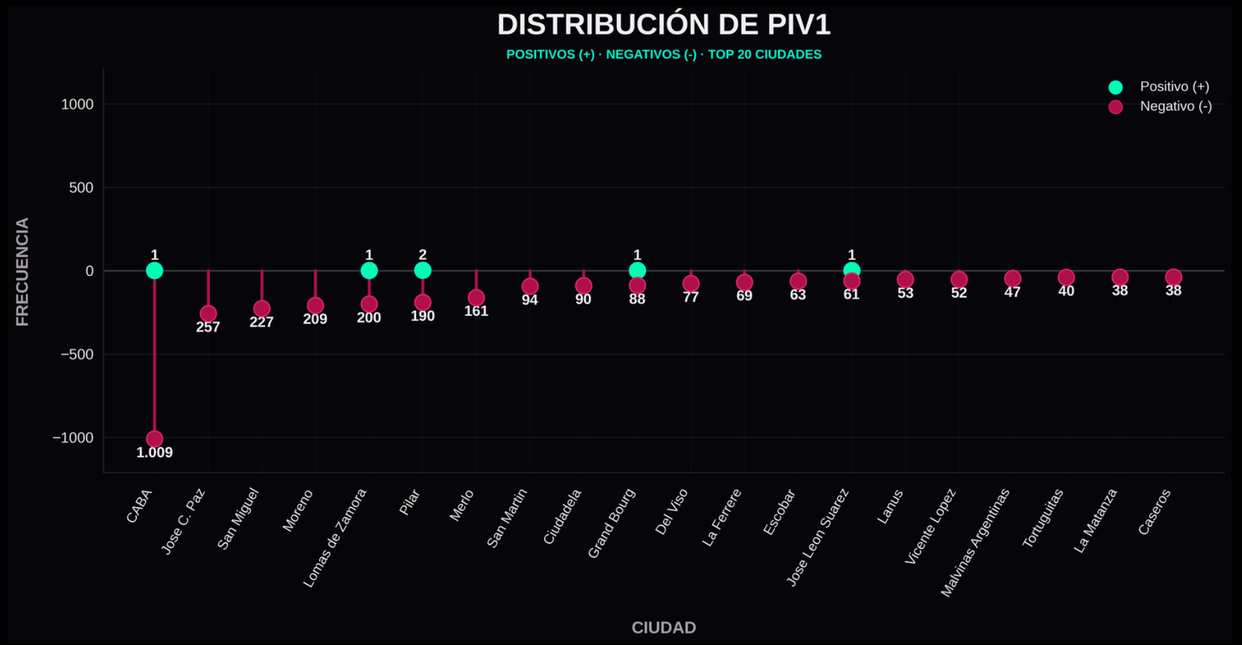
8- Casos de virus por ciudad ↣ Gráficos lollipods

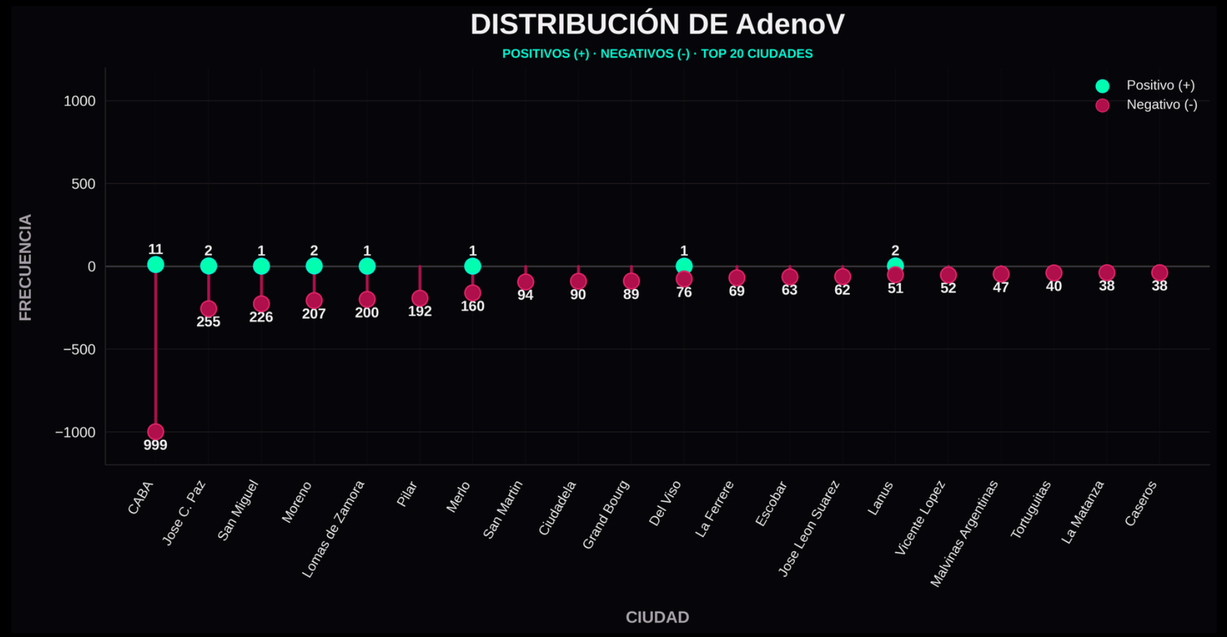


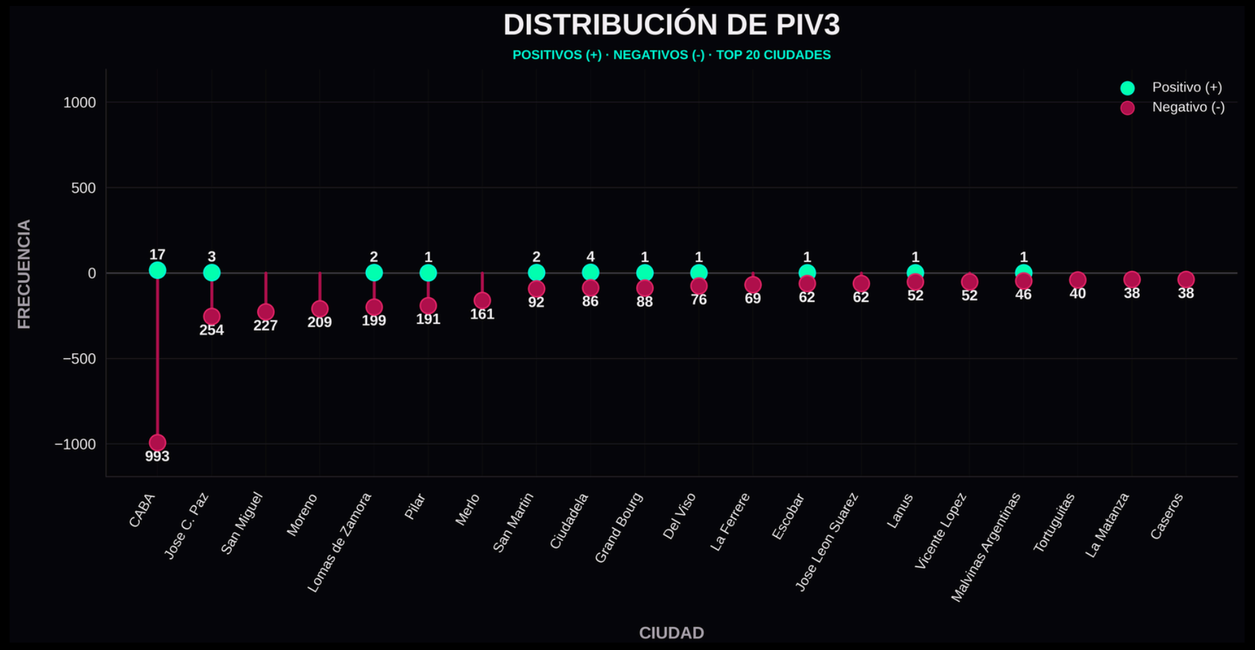
El virus respiratorio sincitial (VRS o RSV) fue el único al parecer en estar distribuido en cada localidad : los casos registrados siguen el efecto de la distancia al establecimiento

En los virus INFA, PIV1, PIV3 y AdenoV, se puede observar que hay localidades en lo que no hubieron casos +.
Para PIV1 faltaría más muestreo, dado que las mediciones del mismo son casi nulas.

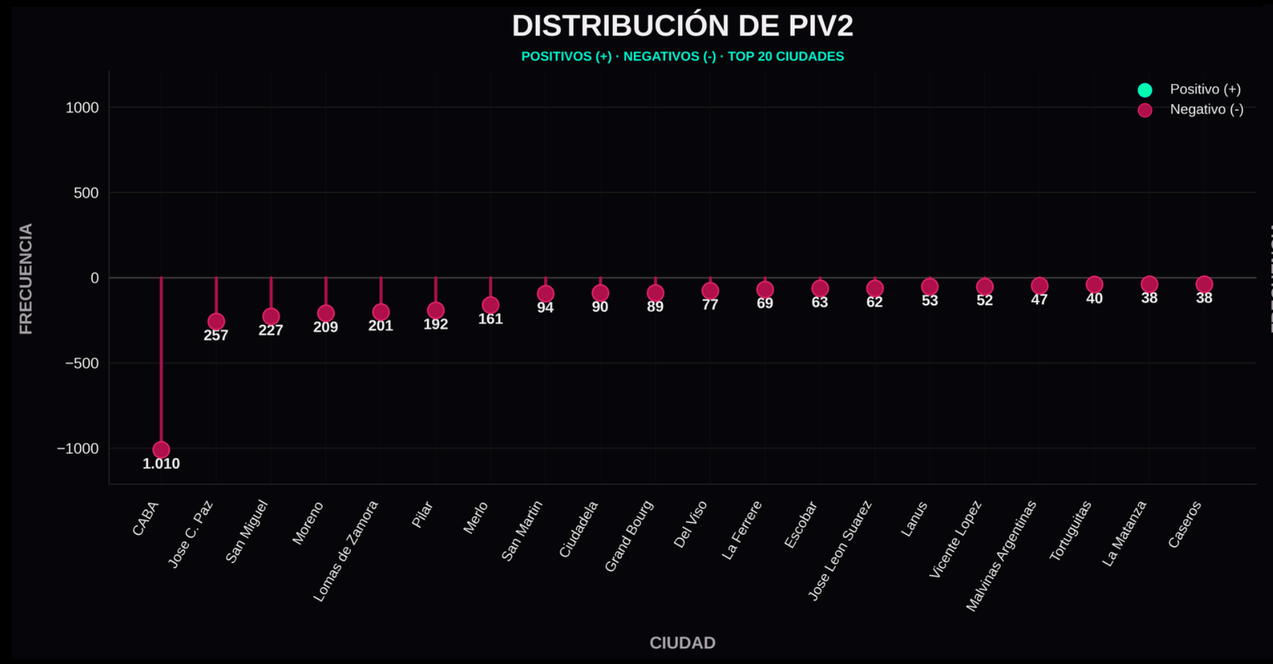


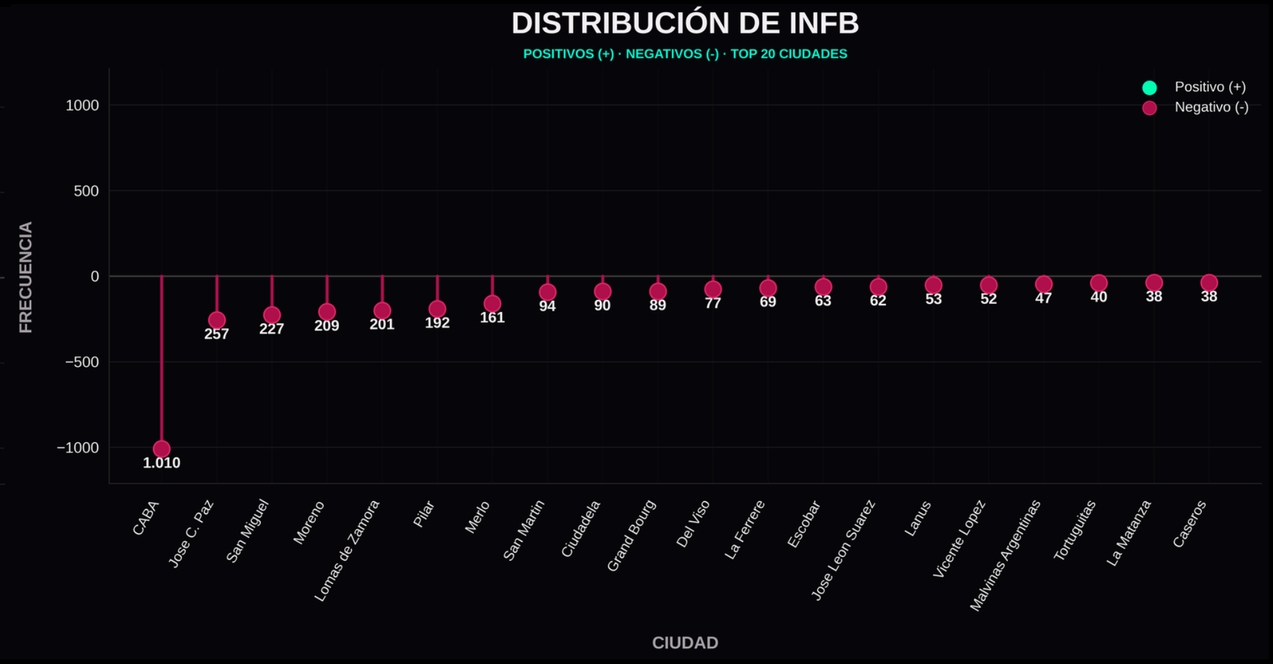






Para PIV2 y INF B no se registraron casos + en ninguna localidad → No hubo incidencia.







9- Análisis de la distribución

A partir del análisis de los gráficos : cada virus tiene un frecuencia diferente en las poblaciones:

- Algunos no tuvieron casos (PIV2 y INF B) → De modo que habría que descartarlos del análisis de casos.

- Otros tienen diferencias en las frecuencias de cada subpoblación (PIV1,INF A, PIV3 y AdenoV).

- Para PIV1 → Poco muestreo (7 casos en total).

- RSV en cambio parece seguir el mismo patrón que la cantidad de casos neta general por población.

Prueba de Hipótesis

Nota: Hay dos virus que presentan problemas y se excluyeron del análisis : INFB y PIV2. Ambos no aportan ninguna información al contraste de composición entre virus, porque su total es 0. Por eso, fueron eliminados de la tabla de contingencia.

Tabla de Contingencia

	AdenoV	RSV	INFA	PIV1	PIV3
Alberti	0	2	0	0	0
Aldo Bonzi	0	1	0	0	0
Alvarez	0	1	0	0	0
Avellaneda	0	7	0	0	2
Azul	0	1	0	0	0
...	...	...	...	...	...
Villa Martelli	0	6	0	0	0
Villa de Mayo	0	2	0	0	0
Virrey del Pino	1	2	0	0	0
Wilde	0	1	0	0	0
William C. Morris	0	1	0	0	0

Resultados del test CHI-CUADRADO

Estadístico χ^2 : 618,2784
Grados de libertad: 496
Valor p : 0,000145

Como valor-p = 0,000145 < 0,05
Se rechaza H_0.

Existe evidencia estadísticamente significativa de que la distribución de casos positivos entre los virus difiere según la localidad.
Esto indica que al menos una localidad presenta una distribución de casos entre virus diferente de la esperada bajo la hipótesis de homogeneidad.

Prueba de Hipótesis

PERO...A diferencia del análisis exploratorio inicial, en este modelo se excluye PIV1 debido a su frecuencia de casos positivos marcadamente inferior respecto de los restantes virus. Esta exclusión no se considera una eliminación de un outlier individual, sino una reducción de una categoría con representación muestral marginal, cuya inclusión puede generar una tabla extremadamente dispersa y frecuencias esperadas muy pequeñas.

Modelo 1 – Pearson x^2

Frecuencia esperada: $$E_{ij} = \frac{n_i \cdot n_j}{n}$$

ni = Número localidades, nj = número de virus positivos y n = total

Estadístico utilizado: $$\chi^2 = \sum_{i}^{n}\sum_{j}^{m} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Oij = Frecuencia observada

Grados de libertad: $$gl = (c-1)(r-1)$$

r = número de localidades y c = número de virus incluidos

Significancia: $\alpha = 0{,}05$

Modelo 2 – Monte Carlo x^2

Bajo H0, se generan repetidamente tablas de contingencia compatibles con la hipótesis de independencia, manteniendo la estructura marginal de los datos.

B representa el número de replicaciones Monte Carlo, en este caso B = 10000

El valor p se estima como la proporción de replicaciones cuyo estadístico es igual o más extremo que el observado

$$p_{MC} = \frac{1 + \sum_{b=1}^{B} I(\chi_b^2 \geq \chi_{obs}^2)}{B+1}$$

El procedimiento permite obtener una estimación empírica de la distribución del estadístico bajo H0, reduciendo la dependencia de la aproximación asintótica del χ^2.

Significancia: $\alpha = 0{,}05$

Prueba de hipótesis - Final

Resultados de ambos modelos

Modelo	χ^2	gl	p-valor
Modelo 1 — Pearson	**396,24**	**369**	**0,1578**
Modelo 2 — Monte Carlo (Simulaciones : 10000)	**396,24**	**369**	**0,3243**

Como valor-p = 0,1578 > 0,05 (Modelo 1) o 0,3243 > 0,05 (Modelo 2)

NO se rechaza H_0.

No existe evidencia estadísticamente suficiente para afirmar que la distribución de casos positivos entre los virus difiera según la localidad según estos dos modelos (En los que se excluye a PIV1 dado su poco muestreo).